

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Detekcija lica u grupnim scenama

T. Antunović, S. Čolaković, E. Smoljan, F. Stamenković, I. Weber

Voditelj: *Marijo Maračić*

Zagreb, prosinac 2014.

SADRŽAJ

1. Uvod i problematika	1
1.1. Detekcija lica	1
1.2. Prepoznavanje lica	1
2. Pregled postojećih rješenja	2
2.1. Detekcija lica	2
2.1.1. Detekcija bazirana na značajkama	2
2.1.2. Detekcija bazirana na slici	3
2.2. Raspoznavanje lica	4
2.3. Primjer primjene: Bostonski maraton	5
3. Predložena implementacija	7
3.1. Detekcija lica	7
3.2. Prepoznavanje lica	8
3.2.1. ICA	9
4. Rezultati	12
5. Zaključak	13
6. Literatura	14
7. Sažetak	16

1. Uvod i problematika

1.1. Detekcija lica

Detekcija lica je prvi korak u sustavima za raspoznavanje lica u proizvoljnim scenama. Cilj detekcije je lokalizacija i ekstrakcija lica iz pozadine. Ljudsko lice ima visok stupanj varijabilnosti na slikama, što čini detekciju lica teškim problemom u području računalnog vida. Ovaj problem je detaljno istraživao i postoje različiti načini kako dobiti zadovoljavajuće rezultate.

1.2. Prepoznavanje lica

2. Pregled postojećih rješenja

2.1. Detekcija lica

Sustavi za detekciju lica se mogu podijeliti na sustave temeljene na značajkama (engl. *feature-based*) i sustave temeljene na slici (engl. *image-based*) [6]. Oni koji su temeljeni na značajkama mogu vršiti analizu slike niskog nivoa koja se oslanja na detekciju rubova, područja intenziteta ili boje, mogu vršiti analizu značajki ili kreirati modele aktivnih oblika (engl. *active shape models*). Sustavi temeljeni na slici se dijele na tri glavne skupine: neuronske mreže, metode linearnih potprostora te razne statističke pristupe.

2.1.1. Detekcija bazirana na značajkama

Sustav za robusnu detekciju lica u realnom vremenu opisan u [16] može poslužiti kao primjer sustava baziranom na značajkama. Temelji se na prikazu slike koji su nazvali “integralna slika”, jednostavnom klasifikatoru koji koristi AdaBoost algoritam učenja za izbor najbitnijih značajki iz velikog skupa, te na kaskadnom kombiniranju klasifikatora koje omogućuje da pozadinske regije budu brzo odbačene i da što je moguće veći dio računanja koncentrira na regije koje imaju veću vjerojatnost da predstavljaju lice.

Modeli aktivnih oblika

Modeli aktivnih oblika predstavljaju značajke višeg nivoa od prethodno spomenutih modela. Kada se inicijalizira u blizini značajke model aktivnog oblika će kroz interakciju s lokalnim značajkama poput rubova i osvjetljenosti postepeno zauzeti oblik značajke višeg nivoa. Na taj način se mogu koristiti ne samo za detekciju lica nego i za prepoznavanje lica kroz označavanje bitnih regija poput očiju, obrva, usta i nosa [14].

Detekcija temeljena na boji

Postupak detekcije lica temeljene na boji kojeg koriste radovi poput [13] i [3] je sljedeći. Prvo detektirati područja na slici koja odgovaraju koži na temelju boje slikovnih elemenata. Potom pronađena područja klasificirati kao lica ili ne-lica. Klasifikacija je potrebna zato što se segmentacijom po boji izdvajaju i dijelovi slike koji prikazuju ostale dijelove tijela (primjerice ruke). U radu [13] se klasifikaciji pristupa tako da se najprije odrede područja u kandidatima za lica koji odgovaraju očima i ustima te se lica prihvaća ako je ocjena pronađenih kandidata bolja od neke granične vrijednosti.



Slika 2.1: Primjer detekcije lica u radu [13].

Rad [3] klasifikaciji pristupa tako da na temelju postojećeg skupa slika lica stvara sliku prosječnog lica. Klasifikacija se vrši tako da se računa korelacija kandidata sa prosječnim licem. Ovaj pristup detaljnije je opisan u poglavlju 3.1.

2.1.2. Detekcija bazirana na slici

Neuronske mreže

Pri detekciji lica korištenjem neuronskih mreža u [12] korišteno je više mreža koje su obavljale različite zadatke. Prva neuronska mreža je vršila procjenu poze potencijalnih regija koje predstavljaju lica. Nakon nje se vršilo preprocesiranje s ciljem smanjivanja

varijacija uzrokovanih osvjetljenjem i razlikama vezanim za kamere. Nakon toga za svaku pozu je korišteno nekoliko neuronskih mreža koje su učile različite stvari iz podataka za treniranje i davale različite rezultate. U posljednjem sloju njihovi izlazi su kombinirani koristeći jednostavnu heuristiku s ciljem povećanja točnih detekcija.

Pristup zasnovan na dubokim konvolucijskim neuronskim mrežama [17] na efikasan način izvlači značajke tokom učenja i na FDDB bazi trenutno ostvaruje najbolje rezultate.

Metode linearnih podprostora

Metode linearnih potprostora su metode poput PCA (engl. *principal component analysis*), ICA (engl. *independent component analysis*), LDA (engl. *linear discriminant analysis*) i FA (engl. *factor analysis*). Pošto unutar predloženog rješenja (poglavlje 3) koristimo PCA i ICA algoritme, ovdje ih nećemo dublje razrađivati.

Statistički pristupi

Kao primjer statističkog pristupa u detekciji lica može poslužiti FloatBoost učenje bazirano na AdaBoost algoritmu [9]. FloatBoost nakon svake iteracije AdaBoost učenja koristi povratni mehanizam za direktnu minimizaciju pogreške. Postiže manju pogrešku učenja i generalizacije koristeći manji broj slabih klasifikatora od AdaBoost algoritma.

2.2. Raspoznavanje lica

Većina algoritama za prepoznavanje lica koriste neki oblik preprocesiranja slike kako bi se dobile značajke pogodne za klasifikaciju. U radu koji nam je dan kao glavna osnova za izradu projekta se koriste metode PCA (principle component analysis) i ICA (independent component analysis), detaljno opisane i uspoređene u [4]. U literaturi ne postoji konceptus o tome koja je metoda bolja u kojim situacijama, ali rad dolazi do zaključka da implementacije ICA metode u prosjeku daju bolje performanse i višu preciznost.

Rad [2] prezentira algoritam raspoznavanja lica u kojem autori nastoje omogućiti precizno raspoznavanje bez obzira na smetnje poput prekrivanja lica, proizvoljnosti položaja i vizualnog šuma. Koriste naučeni koder kako bi dobili opisnik koji se pred kraj obrađuje PCA (principle component analysis) metodom kako bi se smanjile njegove dimenzije i poboljšale performanse algoritma. Detaljnije, nakon detektiranja lica

pronalaže se komponente lica poput nosa, očiju i obraza te se nakon filtriranja šuma dobivaju digitalne reprezentacije njihovih značajki u obliku vektora. Vektori se normaliziraju te se pomoću njih utvrđuje da li se radi o traženom licu. Pretpostavlja se, naravno, da je koder naučen na značajkama lica koja su korištena u treniranju. Algoritam je također u stanju paralelno računanju značajka lica odrediti položaj lica te tu informaciju iskoristiti u konačnoj odluci, čime se poboljšava preciznost. Možda najzanimljiviji dio algoritma je mogućnost kombiniranja više opisnika koristeći poptorni vektor, čime algoritam u konačnosti postiže preciznost od visokih 84.45% na LFW [7] bazi slika.

Rad [10] daje pregled smjera u kojem se trenutno kreću sustavi za raspoznavanje lica i algoritmi koji se pri tome koriste. Opisuje nagli porast interesa za dotično područje u proteklim godinama zbog napretka na području strojnog učenja i računalne grafike te potražnje za sustavima koji koriste tehnologije kojima se bavi računalni put, a neka od primjena su prepoznavanje profilnih slika, automatsko praćenje i promatranje većeg broja ljudi, digitalna rekonstrukcija lica itd. Autor dijeli algoritme za prepoznavanje lica u dvije velike skupine. Prva skupina su algoritmi koji se osnivaju na izgledu, odnosno slikama pojedinaca te se obično koriste u paru sa vektorskim prikazom slika koje obrađuju, što znači da u ovu skupinu pripadaju prije navedeni radovi, a na internetu se nude razne baze podataka slika poput *AT&T Cambridge*¹. Sa druge strane su algoritmi bazirani na modelu, koji nastoje promatrati lica kao 3D modele koji vjerodostojno prikazuju lice sa svim njegovim značajkama te pomoću toga vrše prepoznavanje. Autor navodi neke od algoritama obje skupine te opisuje prednosti i mane svake skupine.

2.3. Primjer primjene: Bostonski maraton

Zanimljiv primjer korištenja računalnog vida u svrhu detekcije i raspoznavanja lica je analiza bombaškog napada na Bostonski maraton 2013. godine.

Detekcija lica na slikama maratona se raspravlja u radu [1], gdje se predlaže algoritam baziran na Viola-Jones algoritmu [15]. Koristeći integralnu sliku i pomični prozor, algoritam prolazi kroz cijelu sliku te provjerava za svaki njen dio da li se na njemu nalazi neko lice. S obzirom da na značajke lica uvelike utječe njegova nakrenutost, algoritam je opremljen detekcijom lica okrenutih prema naprijed, ulijevo ili udesno. Detekcija se vrši nad pomičnim prozorom za svaku od navedenih orijentacija. Algoritam je, osim na slikama maratona, testiran i na FDDB ispitnom skupu te je dao

¹<http://www.cl.cam.ac.uk/research/dtg/attarchive/facedatabase.html>

bolje rezultate od ostalih rješenja. Nažalost, algoritam se pokazao osjetljivim na utjecaj vizualnog šuma i prekrivanja lica, a problem pozicije lica nije u potpunosti riješen.

Raspoznavanje lica je također provedeno nad slikama Bostonskog maratona, a time se bavi rad [8], koji testira dva komercijalna sustava za raspoznavanje lica, PittPatt 5.2.2 i NeoFace 3.1 nad slikama nekooperativnih osumnjičenika, zbog čega su same slike slabije kvalitete. Valja napomenuti da je istraga vezana uz maraton mogla biti puno kraća uz valjane algoritme raspoznavanja, budući da su se slike lica braće Tsarnaev, glavnih osumnjičenika, nalazile u službenoj bazi podataka. Iako ne nudi uvid u rad samih sustava, rad prikazuje varijacije u dobivenim rezultatima ovisno o načinu izbora skupa sa kojim se lica uspoređuju. Sustavi su prvo testirani nad cijelom bazom podataka koja se sastoji od milijun profila te su za svaku danu sliku dobivene tri osobe koje najviše odgovaraju traženom licu, pri čemu je samo NeoFace uspio ispravno prepoznati jednu sliku mlađeg brata. Nakon toga su za svakog brata uneseni dodatni podaci poput spola, rase i dobi što je smanjilo broj mogućih osoba za otprilike šest puta u oba slučaja, a povećanje kvalitete je bilo proporcionalno tom smanjenju. Na kraju se isprobala varijanta sa spajanjem rezultata za svaku osobu koju se pokušalo prepoznati u bazi, čime se dobivaju bolji rezultati ako su pojedinačne slike davale slične rezultate, ali gori ukoliko nisu. Sve u svemu, rad dobro pokazuje utjecaj pristupa testnom skupu.


3. Predložena implementacija

U radu koji će poslužiti kao osnova za izradu ovog projekta [3] za detekciju lica se vrši jednostavna analiza niskog nivoa temeljena na segmentaciji boja, slike i višeslojnom filtriranju tako dobivenih regija koristeći različite vrijednosti pragova sličnosti s prosječnim licem.

3.1. Detekcija lica

Razmotrimo implementaciju detekcije lica temeljene na boji opisanu u [13] i [3]. Prvi dio postupka obuhvaća pronalazak slikovnih elemenata boje kože. Kako bi se bavio efikasno, sliku je potrebno iz RGB prostora konvertirati u YCrCb ili YIQ prostor i onda izgraditi binarnu sliku (masku) u kojoj je svaki piksel označen ako komponente piksela zadovoljavaju uvjet pripadanja koži. Sam uvjet pripadanja piksela području kože varira kroz radove: u [11] koji za obradu koristi YCrCb prikaz uvjet glasi $90 < Y < 180$, $90 < Cr < 130$, $80 < Cb < 150$, dok je u radu [13] utvrđena i opisana zavisnost između Cr, Cb i Y komponenti te se prvo izvršava nelinearna transformacija Cr i Cb komponenti i nakon toga ispituje uvjet pripadanja. Ove opisane metode su empirijske i moguće je da svaki istraživački tim definira svoje u sklopu svog rada. U radu [13] se prije samog stvaranja binarne slike početna slika još provlači kroz fazu pretprocesiranja u kojoj se gleda umanjiti utjecaj izvora svijetlosti na boje u slici. Dobivena binarna maska se još dodatno može transformirati operacijama otvaranja, filtriranja, dilatacije, erozije i zatvaranja kako bi se postigle kompaktnije maske koje predstavljaju moguća područja lica. Dobivena područja se iz slike izvlače postupcima segmentacije.

Potom je potrebno područja slike dobivena segmentacijom klasificirati kao lica odnosno ne-lica. U skladu sa [3] klasifikacija se obavlja na sljedeći način. Na samom početku postoji skup lica koja čine skup za učenje, od tih se lica stvara slika prosječnog lica i za svakog kandidata lica se računa korelacija kandidata sa prosječnim licem. Ako je ta korelacija niska kandidat se odbacuje, inače ako je područje kandidata dovoljno veliko on se prihvća kao područje lica. Test korelacije je sličan načinu na koji se



Slika 3.1: Određivanje područja na slici koja pripadaju koži uz normalni i smanjeni utjecaj svijetlosti.

maximal rejection classifier (MRC) koristi za detekciju lica opisanog u radu [5]. Prihvaćanje kandidata na temelju veličine područja se obavlja koristeći prilagođavajuću granicu prihvaćanja kako bi se omogućilo prihvaćanje malih lica na slici, a istodobno odbacivalo manja područja za koje je prolazak testa korelacije moguć (dijelovi tijela poput ruku).

3.2. Prepoznavanje lica

Nakon što su lica detektirana, izrezana i skalirana lica se prepoznaju korištenjem kombinacije PCA i ICA algoritama. Iako se PCA algoritam može koristiti samostalno za prepoznavanje lica u ovom ćemo ga radu koristiti kao korak predprocesiranja slike. Uz pomoć PCA smanjujemo dimenzionalnost vektora značajki. Ovaj pristup pridonosi kvaliteti rješenja iz više razloga, značajke sa malom varijansom su vjerojatno posljedica šuma i nepoželjne su te se smanjuje složenost modela [4]. Nakon toga, lica se

prepoznaju ICA metodom. Postoje dvije arhitekture te više algoritama ICA metode koji se mogu primjeniti u ovome slučaju.

3.2.1. ICA

ICA (eng. Independent Component Analysis) metoda slična je PCA (eng. Principal Component Analysis) te se može smatrati njenom generalizacijom. Razlika između njih leži u tome što PCA daje nekorelirane bazične vektore, a ICA statistički neovisne vektore. ICA rješava BSS (eng. blind source separation) problem, pokušava prikazati signal kao linearnu kombinaciju nezavisnih signala.

Ako je \mathbf{s} vektor nepoznatih nelinearnih signala, \mathbf{x} opaženi signal i \mathbf{A} matrica transformacije, pokušavamo riješiti sljedeću jednakost:

$$\mathbf{x} = \mathbf{A}\mathbf{s}$$


Pretpostavka je da \mathbf{A} nema inverz. ICA algoritmi pokušavaju naći \mathbf{A} ili \mathbf{W} iz sljedeće jednačbe:

$$\mathbf{u} = \mathbf{W}\mathbf{x} = \mathbf{W}\mathbf{A}\mathbf{s}$$

Moguće je da ne postoji matrica \mathbf{W} koja u potpunosti zadovoljava ovu jednačbu. \mathbf{W} se aproksimira iterativnim postupcima koji maksimiziraju neovisnost bazičnih vektora. Ona se ne maksimizira izravno već se odabiru funkcije koje imaju maksimum kada su vektori nezavisni. ICA algoritam InfoMax maksimizira entropiju postupkom gradijentnog spusta, dok FastICA maksimizira gdje je G nekvaadratna funkcija, v slučajna varijabla, a c neka pozitivna konstanta. Svi ICA algoritmi konvergiraju u isto rješenje te ne postoje velike razlike u njihovim performansama [4].

Arhitektura I


Postoje dva načina za primjenu ICA-e na problemima prepoznavanja lica. Kod prvog načina ulazne slike lica \mathbf{X} promatraju se kao linearna kombinacija nezavisnih slika \mathbf{S} . Primjenom InfoMax algoritma dobivamo \mathbf{U} , aproksimaciju nezavisnih bazičnih slika. Slika 3.2 prikazuje opisanu arhitekturu. Ova arhitektura daje lokalizirane značajke te je bolja za prepoznavanje pokreta lica [4].



Slika 3.2: Arhitektura I


Arhitektura II

Za razliku od prve, druga arhitektura daje globalne značajke te postiže bolje rezultate kod prepoznavanja lica. Cilj ovog načina ICA jest pronalazak nezavisnih koeficijenata za ulazne podatke. Matrica X predstavlja slikovne elemente (eng. pixels) slike, S nezavisne koeficijente ulazne slike, dok je A matrica bazičnih slika.



Slika 3.3: Arhitektura II

Na slici 3.4 možemo vidjeti kakve se značajke dobiju prikazanim arhitekturama. Gornji red prikazuje PCA značajke, srednji ICA značajke uz arhitekturu I, a donji red ICA uz arhitekturu II. Jasno je vidljivo da su značajke ICA II arhitekture globalne. U radu [4] testirani su ICA i PCA algoritmi različitih arhitektura. Vidljivo je da ICA arhitektura II daleko najuspješnija u prepoznavanju lica, pa ćemo je koristiti i u ovom radu. ICA algoritam FastICA postiže malo bolje rezultate od InfoMax-a te njega biramo za ovaj rad.



Slika 3.4: Značajke dobivene PCA, ICA arhitektura I i ICA arhitektura II

4. Rezultati

5. Zaključak

Zaključak.

6. Literatura

- [1] Jeremiah R Barr, Kevin W Bowyer, i Patrick J Flynn. The effectiveness of face detection algorithms in unconstrained crowd scenes. U *Applications of Computer Vision (WACV), 2014 IEEE Winter Conference on*, stranice 1020–1027.
- [2] Zhimin Cao, Qi Yin, Xiaoou Tang, i Jian Sun. Face recognition with learning-based descriptor. U *Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on*, stranice 2707–2714, June 2010. doi: 10.1109/CVPR.2010.5539992.
- [3] D. N. Chandrappa i M. Ravishankar. Automatic face recognition in a crowded scene using multi layered clutter filtering and independent component analysis. U Ajith Abraham, Albert Y. Zomaya, Sebastián Ventura, Ronald Yager, Václav Snásel, Azah Kamilah Muda, i Philip Samuel, urednici, *ISDA*, stranice 552–556. IEEE, 2012. ISBN 978-1-4673-5117-1. URL <http://dblp.uni-trier.de/db/conf/isda/isda2012.html#ChandrappaR12>.
- [4] Bruce A. Draper, Kyungim Baek, Marian Stewart Bartlett, i J. Ross Beveridge. Recognizing faces with pca and ica. *Comput. Vis. Image Underst.*, 91(1-2):115–137, Srpanj 2003. ISSN 1077-3142. doi: 10.1016/S1077-3142(03)00077-8. URL [http://dx.doi.org/10.1016/S1077-3142\(03\)00077-8](http://dx.doi.org/10.1016/S1077-3142(03)00077-8).
- [5] Michael Elad, Yacov Hel-or, i Renato Keshet. Pattern detection using maximal rejection classifier. U *In Int. Workshop on Visual Form*, stranice 28–30, 2000.
- [6] Erik Hjelmås i Boon Kee Low. Face detection: A survey. *Computer Vision and Image Understanding*, 83(3):236–274, Rujan 2001. doi: 10.1006/cviu.2001.0921. URL <http://dx.doi.org/10.1006/cviu.2001.0921>.
- [7] Gary B. Huang, Manu Ramesh, Tamara Berg, i Erik Learned-miller. Labeled faces in the wild: A database for studying face recognition in unconstrained environments.

- [8] Joshua C. Klontz i Anil K. Jain. A case study on unconstrained facial recognition using the boston marathon bombings suspects, 2013.
- [9] Stan Z. Li i ZhenQiu Zhang. Floatboost learning and statistical face detection. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE*, 26(9):2004, 2004.
- [10] Xiaoguang Lu. Image analysis for face recognition.
- [11] Md. Abul Bashar Md. Hafizur Rahman, Suman Chowdhury. An automatic face detection and gender classification from color images using support vector machine.
- [12] Henry A. Rowley, Student Member, Shumeet Baluja, i Takeo Kanade. Neural network-based face detection. *IEEE Transactions On Pattern Analysis and Machine intelligence*, 20:23–38, 1998.
- [13] Andrew Senior, Rein-Lien Hsu, Mohamed Abdel Mottaleb, i Anil K. Jain. Face detection in color images. *IEEE Trans. Pattern Anal. Mach. Intell.*, 24(5):696–706, Svibanj 2002. ISSN 0162-8828. doi: 10.1109/34.1000242. URL <http://dx.doi.org/10.1109/34.1000242>.
- [14] Prabhu Utsav i Keshav Seshadri. Facial recognition using active shape models, local patches and support vector machines.
- [15] Paul Viola i Michael Jones. Rapid object detection using a boosted cascade of simple features. stranice 511–518, 2001.
- [16] Paul Viola i Michael Jones. Robust real-time face detection. *International Journal of Computer Vision*, 57:137–154, 2004.
- [17] Cha Zhang i Zhengyou Zhang. Improving multiview face detection with multi-task deep convolutional neural networks. U *Applications of Computer Vision (WACV), 2014 IEEE Winter Conference on*, stranice 1036–1041. IEEE, 2014.

7. Sažetak

Sažetak.